Лінійний регресійний аналіз

Розділ I. § 1. Класична регресійна модель та її узагальнення.

1.1 Описова регресія.

На практиці часто виникає потреба знаходження залежності між деякими величинами. Ця залежність може бути отримана за допомогою теорії або експериментально. Якщо залежність отримана за допомогою теоретичних міркувань, то, доволі часто, вона може бути записана в аналітичному вигляді, заданому з точністю до кількох параметрів. Якщо ж в основі побудови залежності лежать експериментальні дані, то параметрична залежність постулюється. В обох випадках при побудові математичної моделі повинні використовуватись відомості про досліджуваний об'єкт, на підставі яких можна було б зробити висновок про достатню точність опису об'єкта моделлю, а, отже, про те, що проведені статистичні висновки в пеовному розумінні є вірними і по відношенню до самого об'єкта.

Подамо опис аналізу залежності серед набору деяких величин.

Нехай задано набір (m+1) – кількісних величин $y, x_1, ..., x_m$ і $N \geq m$ результатів вимірів, які об'єднанні в матрицю емпіричних даних

$$(Y, F) = \begin{pmatrix} y_1 & x_{11} & \dots & x_{1m} \\ \vdots & & & \\ y_N & x_{N1} & \dots & x_{Nm} \end{pmatrix};$$

$$Y = (y_1, ..., y_N)^T; \qquad F = \begin{pmatrix} x_{11} & \dots & x_{1m} \\ \vdots & & \\ x_{N1} & \dots & x_{Nm} \end{pmatrix},$$

де Y – вектор результатів вимірів, а F – матриця плану експерименту.

Якщо вимагати, щоб y проходила через точку x_1, то одержимо задачу побудови прямої лінії.

В загальному випадку, тільки поліном високого порядку може пройти через всі точки, але на практиці потрібно відшукати функцію відносно просту (лінійну), яка з задовільною точністю апрокстимує статистичну залежність. В загальній постановці задача опису емпіричної залежності за допомогою параметричної регресії припускає, що задається функція, визначена з точністю до кількох параметрів, які підбирають таким чином, щоб одержана функція з максимальною точністю відповідала емпіричним даним. Функцію $\eta = \eta(x)$ при цьому називають емпіричною регресією. Після вибору типу η необхідно знайти такі значення $\theta_1, ..., \theta_m$, за яких функція регресії буде досить добре, а може, і найкращим чином описувати емпіричні дані. Для розв'язування такої задачі необхідно задати критерій, який би визначав ступінь відповідності емпіричних даних і регресійної залежності. Тобто необхідно враховувати відхилення між вимірами $y_1, ..., y_N$ і $\hat{y}_j = \sum_{i=1}^{m} x_{ji}\theta_i$.

Якщо позначити відхилення $\varepsilon_j = y_j - \hat{y}_j$, $j = 1,...,N$, то $\hat{y}_j = \sum_{i=1}^{m} x_{ji}\theta_i + \varepsilon_j$, $j = 1,...,N$, або в матричній формі $\mathbf{Y} = F\theta + \varepsilon$, де $\boldsymbol{\theta} = (\theta_1,...,\theta_m)^T$ - вектор невідомих параметрів, $\boldsymbol{\varepsilon} = (\varepsilon_1,...,\varepsilon_N)^T$ - вектор відхилень.

При заданій матриці (Y,F) вектор ε залежить від $\boldsymbol{\theta}$, тому від вибору $\boldsymbol{\theta}$ залежить якість регресійного опису. Критерії оптимального вибору $\boldsymbol{\theta}$ можуть задаватись різними способами, наприклад, ті $\boldsymbol{\theta}$, для яких $\max_{j=1,...,N} |\varepsilon_j|$, $\sum_{j=1}^{N} |\varepsilon_j|$, $\boldsymbol{\varepsilon}^{\mathbf{T}}\boldsymbol{\varepsilon} = \sum_{j=1}^{N} \varepsilon_j^2$ є мінімальними, тобто певним чином вибрана норма.

Розглянемо третій із вказаних критеріїв, оскільки, у цьому випадку одержуються достатньо прості формули для обчислення $\boldsymbol{\theta}$, а самі ці значення володіють певними властивостями оптимальності.

<u>Означення 1.</u> Нехай на множині X задана обмежена знизу функція f(x), яка на цій множині досягає мінімального значення. Тоді $\arg\min_{x \in X} f(x)$ розуміється довільна точка мінімуму f на X, тобто $x_* \in X$, в якій $f(x_*) = \min_{x \in X} f(x)$.

<u>Означення 2.</u> Вектор

$$\hat{\theta} = \arg\min_{\theta \in R^m} (Y - F\theta)^T (Y - F\theta) = \arg\min_{\theta \in R^m} \varepsilon^T \varepsilon \qquad (1)$$

називається емпіричною оцінкою методу найменших квадратів (МНК).

<u>Лема 1.1</u> Вектор (1) є розв'язком системи рівнянь

$$F^T F\theta = F^T Y . \qquad (2)$$

Доведення:

Розглянемо

$$Q(\theta) = (Y - F\theta)^T (Y - F\theta) = \sum_{j=1}^{N} \left(y_j - \sum_{i=1}^{m} x_{ji}\theta_i \right)^2 .$$

Функція $Q(\theta)$ визначена на R^m і невід'ємна, а тому вона досягає мінімуму. $\frac{\partial Q}{\partial \theta_l} = 2\left[\sum_{j=1}^{N} \sum_{i=1}^{m} x_{jl} x_{ji} \theta_i - \sum_{j=1}^{N} x_{jl} y_j \right]$. Записуючи в матричному вигляді, отримаємо доведення леми.

Якщо матриця $F^T F$ невироджена, то $\hat{\theta} = (F^T F)^{-1} F^T Y$.

Лему доведено ▲

<u>Приклад 1.1.</u>

$y = x^2$; $x_1 = 0$; $x_2 = \frac{1}{2}$; $x_3 = 1$. $\eta(x) = \theta_1 + \theta_2 x$.

Знайти МНК-оцінку $\hat{\theta}$.

$$\hat{\theta} = (F^T F)^{-1} F^T Y$$

$$Y=\begin{pmatrix}0\\1/4\\1\end{pmatrix}\quad F=\begin{pmatrix}1&0\\1&1/2\\1&1\end{pmatrix};\quad F^TF=\begin{pmatrix}3&3/2\\3/2&5/4\end{pmatrix};\quad \det F^TF=\frac{3}{2};$$

$$\left(F^TF\right)^{-1}=\begin{pmatrix}5/6&-1\\-1&2\end{pmatrix};\ \hat{\theta}=\begin{pmatrix}-1/12\\1\end{pmatrix}.$$

1.2. Основні означення і деякі властивості оцінок.

В матричному вигляді довільна лінійна регресійна модель (схема лінійної регресії) записується $Y=F\theta+\varepsilon$, $\varepsilon\sim(0,\Sigma)$, де $Y=(y_1,...,y_N)^T$ - вектор результатів вимірів, F – фіксована регресійна матриця плану розміру $N\times m$ (елементи якої – відомі коефіцієнти лінійної регресії), $\varepsilon=(\varepsilon_1,...,\varepsilon_N)^T$ - вектор неспостережуваних випадкових похибок, тобто випадкових величин на деякому ймовірнісному просторі з нульовим середнім ($E\varepsilon=0$) і заданою дисперсійною матрицею ($\Sigma=E\varepsilon\varepsilon^T=(M\varepsilon_i\varepsilon_j)$, $i,j=1,...,N$).

Якщо необхідно здійснювати перевірку гіпотез про значення перших двох моментів випадкового вектора ε, то потрібно знати повністю його розподіл.

Будемо позначати таку модель впорядкованою трійкою $(Y,F\theta,\Sigma)$, де $\Sigma=\delta^2 I$ (δ - залиш. дисп.).

Основна відмінність даної моделі від описової регресії полягає в додатковому припущенні про випадковість ε.

<u>Приклади моделей.</u>

<u>Приклад 1.2.</u> Лінійна регресія на відрізку.

$$\eta(x)=\theta_1+\theta_2x,\qquad x\in[-1,1]\qquad\Rightarrow\qquad y_j=\theta_1+\theta_2x_j+\varepsilon_j,\qquad j=1,...,N.$$

$$Y=(y_1,...,y_N)^T;\ F=\begin{pmatrix}1&x_1\\\vdots&\vdots\\1&x_N\end{pmatrix};\ \varepsilon=(\varepsilon_1,...,\varepsilon_N)^T,\ \theta=\begin{pmatrix}\theta_1\\\theta_2\end{pmatrix},\ Y=F\theta+\varepsilon.$$

<u>Приклад 1.3.</u> Квадратична регресія на відрізку

$$\eta(x)=\theta_1+\theta_2x+\theta_3x^2,\ x\in[-1,1].$$

$$Y=(y_1,...,y_N)^T,\ \theta=(\theta_1,\theta_2,\theta_3)^T.\ F=\begin{pmatrix}1&x_1&x_1^2\\\vdots&\vdots&\vdots\\1&x_N&x_N^2\end{pmatrix}.$$

<u>Приклад 1.4.</u> Сформулюємо схему регресії для задачі визначення ваг $\theta_1,\theta_2,\theta_3$ трьох предметів на двошалькових терезах. Припустимо, що результат j-го виміру є різниця ваг другої і першої шальки плюс деяка некорельована похибка ε_j, $M\varepsilon_j=0$, $D\varepsilon_j=\sigma^2$, $M\varepsilon_j\varepsilon_i=0$.

$$y_j = \theta_1 x_{1j} + \theta_2 x_{2j} + \theta_3 x_{3j} + \varepsilon_j,$$ де

$$x_{lj} = \begin{cases} (-1)^{m_{LJ}}, \ \textit{якщо } l-\textit{й вантаж зважували в } j-\textit{му експерименті} \\ 0 - \textit{в протилежному випадку} \end{cases};$$

де m_{lj} - номер чашки, на якій лежить вантаж.

Далі ми часто будемо використовувати клас лінійних однорідних оцінок $\tilde{\theta} = CY$, де С – довільна матриця розміру $m \times N$.

Важливою властивістю оцінок є їх незміщеність.

<u>Лема 1.2.</u>

Для схеми лінійної регресії $(Y, F\theta, \Sigma)$ лінійна оцінка $\tilde{\theta} = CY$ є незміщеною тоді і тільки тоді, коли $CF = I_m$, де I_m - одинична матриця розміру $m \times m$.

Доведення.

Оскільки MY=Fθ, то $M\tilde{\theta} = MCY = CF\theta$. Покажемо, що виконання умови $CF\theta = \theta \ \ \forall \theta \in \mathbf{R}^m$ рівносильно виконанню умов леми.

Домножаючи справа $CF = I_m$ на θ, отримаємо $CF\theta = \theta$. З іншого боку, взявши замісь θ вектор $c_i = (0,...,1,...,0)$ *(i=1,...,m)*, отримаємо покомпонентну рівність $CF = I_m$. Лему доведено.▲

Позначимо $\Xi(\theta)$ множину всіх лінійних незміщених оцінок параметра θ. Найкращою лінійною незміщеною оцінкою (НЛН) параметрів θ (у випадку її існування) називається така оцнка $\theta \in \Xi$, що $D\hat{\theta} \le D\tilde{\theta} \ \ \forall \ \tilde{\theta} \in \Xi$.

Із властивостей невід'ємно визначених матриць випливає, що якщо $\hat{\theta}$ є НЛН оцінкою, то $\det D\hat{\theta} \le \det D\tilde{\theta}$, $a^T[D\hat{\theta}]a \le a^T[D\tilde{\theta}]a$ і $[D\hat{\theta}_{ii}] \le [D\tilde{\theta}_{ii}]$ для всіх $\tilde{\theta} \in \Xi$, $a \in R^m$, *i=1,2,...,m*; де $[D]_{ii}$ - діагональний елемент.

Нехай задана лінійна регресійна модель $(Y, F\theta, \Sigma)$, де матриця F має повний ранг, тобто *rangF=m*. При цьому говорять, що модель є невиродженою або повного рангу. Стандартною МНК-оцінкою параметрів θ називається вектор $\hat{\boldsymbol{\theta}} = (F^T F)^{-1} F^T Y$.

Згідно з лемою 1.1 $\hat{\theta} = \arg\min\limits_{\theta \in R^m} (Y - F\theta)^T (Y - F\theta)$. Очевидно, оцінка $\hat{\theta}$ є лінійною і незміщеною.

$$M\hat{\theta} = \left(F^T F\right)^{-1} F^T MY = \left(F^T F\right)^{-1} F^T F\theta = \theta.$$

Наведемо приклади обчислення МНК-оцінок.

<u>Приклад 1.5.</u> МНК-оцінка для лінійної регресії на відрізку.

$$F^T F = \begin{pmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_N \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_N \end{pmatrix} = \begin{pmatrix} N & \sum_{j=1}^{N} x_j \\ \sum_{j=1}^{N} x_j & \sum_{j=1}^{N} x_j^2 \end{pmatrix};$$

$$\det F^T F = N \sum_{j=1}^{N} x_j^2 - \left(\sum_{j=1}^{N} x_j \right)^2; \qquad \left(F^T F\right)^{-1} = \left(\det F^T F\right)^{-1} \begin{pmatrix} \sum_{j=1}^{N} x_j^2 & -\sum_{j=1}^{N} x_j \\ -\sum_{j=1}^{N} x_j & N \end{pmatrix};$$

$$\hat{\theta} = \left(\det F^T F\right)^{-1} \begin{pmatrix} \sum_{j=1}^{N} x_j^2 \sum_{j=1}^{N} y_j - \sum_{j=1}^{N} x_j \sum_{j=1}^{N} x_j y_j \\ N \sum_{j=1}^{N} x_j y_j - \sum_{j=1}^{N} x_j \sum_{j=1}^{N} y_j \end{pmatrix};$$

$$\hat{\theta}_1 = \left(\sum_{j=1}^{N} x_j^2 \sum_{j=1}^{N} y_j - \sum_{j=1}^{N} x_j \sum_{j=1}^{N} x_j y_j \right) \Bigg/ \left(N \sum_{j=1}^{N} x_j^2 - \left(\sum_{j=1}^{N} x_j \right)^2 \right);$$

$$\hat{\theta}_2 = \left(N \sum_{j=1}^{N} x_j y_j - \sum_{j=1}^{N} x_j \sum_{j=1}^{N} y_j \right) \Bigg/ \left(N \sum_{j=1}^{N} x_j^2 - \left(\sum_{j=1}^{N} x_j \right)^2 \right).$$

Якщо точки вибрані так, що $\sum_{j=1}^{N} x_j = 0$, то $\hat{\theta}_1 = \frac{1}{N} \sum_{j=1}^{N} y_j$; $\hat{\theta}_2 = \sum_{j=1}^{N} x_j y_j \Big/ \sum_{j=1}^{N} x_j^2$. При *N=3*, $x_1 = -1$, $x_2 = 0$, $x_3 = 1$

$$\hat{\theta} = \begin{pmatrix} (y_1 + y_2 + y_3)/3 \\ (y_3 - y_1)/2 \end{pmatrix}.$$

<u>Приклад 1.6.</u> МНК-оцінка для квадратичної регресії.

$\sum_{j=1}^{N} x_j = 0$; $\sum_{j=1}^{N} x_j^3 = 0$.

$$F^T F = \begin{pmatrix} N & 0 & \sum_{j=1}^{N} x_j^2 \\ 0 & \sum_{j=1}^{N} x_j^2 & 0 \\ \sum_{j=1}^{N} x_j^2 & 0 & \sum_{j=1}^{N} x_j^4 \end{pmatrix};$$ Позначимо $a = \sum_{j=1}^{N} x_j^2$; $b = \sum_{j=1}^{N} x_j^4$;

$c = Nab - a^3$ і припустимо, що $c = \det F^T F \neq 0$.

Тоді:

$$\hat{\theta} = \begin{pmatrix} \frac{a}{c}\left(b\sum_{j=1}^{N} y_j - a\sum_{j=1}^{N} x_j^2 y_j \right) \\ \frac{Nb-a^2}{c}\sum_{j=1}^{N} x_j y_j \\ \frac{a}{c}\left(N\sum_{j=1}^{N} x_j^2 y_j - a\sum_{j=1}^{N} y_j \right) \end{pmatrix}.$$

При $N=3 \Rightarrow$ $\hat{\theta}_1 = y_2$, $\hat{\theta}_2 = \frac{1}{2}(y_3 - y_1)$,

$\hat{\theta}_3 = \frac{1}{2}[3(y_1+y_2) - 2(y_1+y_2+y_3)] = \frac{1}{2}(y_1+y_3) - y_2$.

1.3. Теорема Гауса-Маркова для класичної лінійної регресії.

Тип дисперсійної матриці $DY = \Sigma$ визначає як назву лінійної регресійної моделі $(Y, F\theta, \Sigma)$, так і оптимальні способи оцінювання невідомих параметрів. Найбільш простим є випадок, коли похибки $\varepsilon = (\varepsilon_1, ..., \varepsilon_N)^T$ є некорельованими і мають однакову дисперсію, тобто $\Sigma = \sigma^2 I_N$, де σ^2 - дисперсія одного виміру. В цьому випадку модель $(Y, F\theta, \sigma^2 I_N)$ називається класичною лінійною регресійною моделлю. Перш, ніж сформулювати і довести основний результат для класичної лінійної регресійної моделі, розглянемо, як обчислюються дисперсійні матриці лінійних незміщених оцінок.

<u>Лема 1.3</u>

Нехай ξ - деякий випадковий вектор розміру p, $D\xi = M(\xi - M\xi)(\xi - M\xi)^T$ - його скінчена дисперсійна матриця, a – довільно фіксований вектор розміру q, а L – задана $q \times p$-матриця. Тоді дисперсійна матриця випадкового вектора $\eta = L\xi + a$ визначається за формулою $D\eta = LD\xi L^T$.

Доведення.

$$D\eta = M(\eta - M\eta)(\eta - M\eta)^T = M(L\xi + a - ML\xi - a)(L\xi + a - ML\xi - a)^T =$$
$$M[L(\xi - M\xi)][L(\xi - M\xi)]^T = L\left(M(\xi - M\xi)(\xi - M\xi)^T\right)L^T = LD\xi L^T.$$

Лему доведено. ▲

<u>Лема 1.4.</u>

Нехай задана класична лінійна регресійна модель $(Y, F\theta, \sigma^2 I_N)$ і $\tilde{\theta} = CY$ - довільна лінійна статистика, тоді $D\tilde{\theta} = \sigma^2 CC^T$.

Доведення.

Використаємо попередню лему і те, що $D\xi = \sigma^2 I_N$. Лему доведено. ▲

Зауваження. З леми 1.4 випливає, що для класичної лінійної регресійної моделі повного рангу дисперсійна матриця стандартної МНК оцінки $D\hat{\theta} = \sigma^2\left(F^T F\right)^{-1}$.

Дійсно, $\hat{\theta} = C_0 Y$, де $C_0 = \left(F^T F\right)^{-1} F^T$, тому $D\hat{\theta} = \sigma^2 C_0 C_0^T = =$ $\sigma^2\left(F^T F\right)^{-1} F^T\left[\left(F^T F\right)^{-1} F^T\right]^T = \sigma^2\left(F^T F\right)^{-1} F^T F\left(F^T F\right)^{-1} = \sigma^2\left(F^T F\right)^{-1}$.

Теорема 1.1. (Гауса-Маркова).

Нехай задана класична лінійна регресійна модель $(Y, F\theta, \sigma^2 I_N)$, де F – матриця повного рангу(rangF = m). Тоді МНК-оцінка є НЛН-оцінкою.

Доведення.

Нехай $\tilde{\theta} = CY$ - довільна лінійна незміщена оцінка параметрів θ, а $\tilde{\theta} = C_0 Y$ - МНК-оцінка, $C_0 = \left(F^T F\right)^{-1} F^T$. Запишемо умову незміщеності для θ і $\hat{\theta}$:

$$CF = I_m,\ C_0 F = I_m. \qquad (3)$$

Покладемо $A = C - C_0$, тоді з рівностей (3) отримаємо AF= $(C - C_0)F = CF - C_0 F = I_m - I_m = 0$. Отже, $AC_0^T = AF\left(F^T F\right)^{-1}$=0.

$$D\tilde{\theta} = \sigma^2 CC^T = \sigma^2\left[C_0 + A\right]\left[C_0^T + A^T\right] = \sigma^2\left[C_0 C_0^T + C_0 A^T + AC_0^T + AA^T\right] =$$
$$= \sigma^2 C_0 C_0^T + \left[AC_0^T + \left(AC_0^T\right)^T\right] + \sigma^2 AA^T = D\hat{\theta} + \sigma^2 AA^T.$$

Так як $AA^T \geq 0$, то $D\tilde{\theta} \geq D\hat{\theta}$. Теорему доведено.▲

1.4. Оцінювання дисперсії в класичній лінійній регресійній моделі.

В даному пункті проведемо оцінку невідомої дисперсії одного виміру σ^2 в невиродженій класичній лінійній регресійній моделі $(Y, F\theta, \sigma^2 I_N)$.

Теорема 1.2.

Незміщеною оцінкою для σ^2 в невиродженій моделі $(Y, F\theta, \sigma^2 I_N)$ є статистика $s^2 = (Y - F\hat{\theta})^T (Y - F\hat{\theta}) \big/ (N - m)$, де $\hat{\theta}$ - МНК-оцінка параметрів θ.

Доведення.

Покладемо $\hat{\varepsilon} = Y - F\hat{\theta}$, тоді $\hat{\varepsilon} = Y - F\left(F^T F\right)^{-1} F^T Y = =$ $F\theta + \varepsilon - F\left(F^T F\right)^{-1} F^T (F\theta + \varepsilon) = F\theta + \varepsilon - F\left(F^T F\right)^{-1} F^T F\theta - F\left(F^T F\right)^{-1} F^T \varepsilon =$ $\left(I_N - F\left(F^T F\right)^{-1} F^T\right)\varepsilon$. Тобто $\hat{\varepsilon} = G\varepsilon$, де $G = I_N - F\left(F^T F\right)^{-1} F^T$. Матриця G ідемпотентна, тобто $G = G^T$ і $G^2 = G$.

$$G^T = I_N - \left(F\left(F^T F\right)^{-1} F^T \right)^T = I_N - F\left(F^T F\right)^{-1} F^T .$$

$$G^2 = \left(I_N - F\left(F^T F\right)^{-1} F^T \right)\left(I_N - F\left(F^T F\right)^{-1} F^T \right) = \quad =$$

$$I_N - 2F\left(F^T F\right)^{-1} F^T + F\left(F^T F\right)^{-1} F^T F\left(F^T F\right)^{-1} F^T \quad = \quad I_N - F\left(F^T F\right)^{-1} F^T \quad = \quad G.$$

Враховуючи таку властивість, маємо: $\hat{\varepsilon}^T \hat{\varepsilon} = \varepsilon^T G^T G\varepsilon = \varepsilon^T G^2 \varepsilon = \varepsilon^T G\varepsilon$.

Якщо $\exists AB$ і $\exists\ BA$, то $trAB=trBA$, крім того, операція tr та знаходження математичного сподівання комутують між собою, отримаємо:

$$M\hat{\varepsilon}^T \hat{\varepsilon} = Mtr\varepsilon^T G\varepsilon = MtrG\varepsilon\varepsilon^T = trGM\varepsilon\varepsilon^T = \sigma^2 trG = \quad =$$

$$\sigma^2\left(trI_N - trF^T F\left(F^T F\right)^{-1} \right) = = \sigma^2\left(trI_N - trI_m\right) = \sigma^2\left(N-m\right).$$

Отже, $Ms^2 = \sigma^2$. Теорема доведена.

<u>Приклад 1.7.</u> (продовження прикладу 1.5.)

$$Y - F\theta = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix} - \begin{pmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_N \end{pmatrix}\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} y_1 - \hat{\theta}_1 - \hat{\theta}_2 x_1 \\ \vdots \\ y_N - \hat{\theta}_1 - \hat{\theta}_2 x_N \end{pmatrix};$$

$$s^2 = \frac{1}{N-2}\sum_{i=1}^{N}\left(y_i - \hat{\theta}_1 - \hat{\theta}_2 x_i \right)^2 = =$$

$$\frac{1}{N-2}\sum_{i=1}^{N}\left(y_i - \frac{1}{N}\sum_{j=1}^{N} y_j - x_i \sum_{j=1}^{N} x_j y_j \left(\sum_{j=1}^{N} x_j^2 \right)^{-1} \right)^2 .$$

Припустимо, що істинна функція регресії має вигляд $\eta = 1 + 2x$, $N=6$, $x_1 = -1$, $x_2 = -0.6$, $x_3 = -0.2$, $x_4 = 0.2$, $x_5 = 0.6$, $x_6 = 1$. З таблиці нормально розподілених чисел беремо 6 величин: $\varepsilon_1 = -0.45$, $\varepsilon_2 = 1.68$, $\varepsilon_3 = -0.06$, $\varepsilon_4 = -1.23$, $\varepsilon_5 = -0.49$, $\varepsilon_6 = 0.86$. Тобто вважаємо, що результатами експериментів є числа $y_1 = -1 - 0.49 = -1.49$; $y_2 = 1.48$; $y_3 = 0.54$; $y_4 = 0.17$; $y_5 = 1.71$; $y_6 = 3.86$.

Побудуємо МНК-оцінку параметрів регресії

$$F^T F = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ -1 & -0.6 & -0.2 & 0.2 & 0.6 & 1 \end{pmatrix}\begin{pmatrix} 1 & -1 \\ 1 & -0.6 \\ 1 & -0.2 \\ 1 & 0.2 \\ 1 & 0.6 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 6 & 0 \\ 0 & 2.8 \end{pmatrix};$$

$$\left(F^T F\right)^{-1} = \begin{pmatrix} 0.17 & 0 \\ 0 & 0.36 \end{pmatrix}; \quad F^T Y = \begin{pmatrix} 6.27 \\ 5.41 \end{pmatrix};$$

$$\hat{\theta} = \begin{pmatrix} 0.17 & 0 \\ 0 & 0.36 \end{pmatrix} \begin{pmatrix} 6.27 \\ 5.41 \end{pmatrix} = \begin{pmatrix} 1.07 \\ 1.95 \end{pmatrix}.$$

Обчислимо s^2:

$$Y - F\theta = (-0.61 \quad 1.58 \quad -0.14 \quad -1.29 \quad -0.53 \quad 0.84)^T .$$

$$s^2 = \frac{\left(Y - F\hat{\theta}\right)^T \left(Y - F\hat{\theta}\right)}{6-2} = \frac{0.37 + 2.50 + 0.02 + 1.66 + 0.28 + 0.70}{4} = \frac{5.53}{4} = 1.38$$

1.5. Принцип максимальної вірогідності (правдоподібності) для класичної лінійної регресійної моделі.

Для отримання результатів з попередніх пунктів не потрібно знати вигляд розподілу ε, а необхідно знати середнє значення і Σ. Тепер ми будемо припускати, що $\varepsilon \sim N(a, \Sigma)$, тобто,

$$f(x, a, \Sigma) = 2\pi^{-\frac{N}{2}} \left(\det \Sigma\right)^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}(x-a)^T \Sigma^{-1} (x-a)\right\}.$$

Якщо *a=0*; $\Sigma = \sigma^2 I_N$, то $f(x, 0, \sigma^2 I_N) = \left(2\pi\sigma^2\right)^{-\frac{N}{2}} \exp\left\{-x^T x / \left(2\sigma^2\right)\right\}$.

<u>Теорема 1.3.</u>

Нехай задана невироджена класична лінійна регресійна модель, $Y = F\theta + \varepsilon$, $\varepsilon \sim N\left(0, \sigma^2 I_N\right)$. Тоді МНК-оцінка є оцінкою максимальної правдоподібності, а статистика $\tilde{s}_N^2 = \dfrac{(N-m)s^2}{N}$ - ОМП оцінкою параметра σ^2.

Доведення.

Оскільки $Y \sim N\left(F\theta, \sigma^2 I_N\right)$, отже, функція максимальної правдоподібності має вигляд

$$L\left(Y, \theta, \sigma^2\right) = \left(2\pi\sigma^2\right)^{-\frac{N}{2}} \exp\left\{-\frac{1}{2\sigma^2}(Y - F\theta)^T (Y - F\theta)\right\};$$

$$\ln L\left(Y, \theta, \sigma^2\right) = -\frac{N}{2} \ln 2\pi\sigma^2 - \frac{1}{2\sigma^2}(Y - F\theta)^T (Y - F\theta).$$

Знайдемо максимум останньої функції:

$$\begin{cases} \sigma^2 \dfrac{\partial \ln L}{\partial \theta} = F^T (Y - F\theta) = 0 \\ 2\sigma^2 \dfrac{\partial \ln L}{\partial \sigma^2} = -N + \dfrac{1}{\sigma^2}(Y - F\theta)^T (Y - F\theta) = 0 \end{cases}$$

Перше рівняння – це нормальна система, розв'язок якої є МНК-оцінка $\hat{\theta}$. Розв'язком другого рівняння є $\tilde{s}_N^2$. Теорема доведена.

<u>Зауваження.</u> ОМП-оцінка $\tilde{s}_N^2$ для σ^2 є зміщеною.

Приклад 1.8.

Припустимо, що функція регресії – стала, тобто $y_j = \theta + \varepsilon_j$, $M\varepsilon_i\varepsilon_j = \begin{cases} 0, i \neq j \\ \sigma^2, i = j \end{cases}$. В даному випадку $F=(1,1,...,1)^T$, $F^T F = N$, $\left(F^T F\right)^{-1} = N^{-1}$; $F^T Y = \sum_{j=1}^{N} y_j$; $\hat{\theta} = \frac{1}{N}\sum_{j=1}^{N} y_j = \bar{y}$. Отже, МНК-оцінка θ - вибіркове середнє.

Незміщена оцінка для дисперсії : $S^2 = \frac{1}{N-1}\sum_{j=1}^{N}(y_j - \bar{y})^2$.

1.6. Перевірка гіпотез про коефіцієнти регресії

Сформулюємо задачу про перевірку гіпотези $H_0 : \theta_i = a \quad \left(i = \overline{1,m}\right)$ при альтернативній $H_1 : \theta_i \neq a$. В даній моделі $\hat{\theta} = \left(\hat{\theta}_1,...,\hat{\theta}_m\right)^T \sim N\left(\theta, \sigma^2\left(F^T F\right)^{-1}\right)$. У випадку справедливості гіпотези H_0 маємо $\hat{\theta}_i \sim N\left(a, D\hat{\theta}_i\right)$, де $D\hat{\theta}_i = \sigma^2\left[\left(F^T F\right)^{-1}\right]_{ii}$ - і-й діагональний елемент.

1) Якщо значення σ^2 є відомим, то статистика $u = \frac{(\hat{\theta}_i - a)}{\sqrt{D\hat{\theta}_i}} \sim N(0,1)$

2) Якщо значення σ^2 невідоме, то для оцінки використовують статистику $t = \frac{\left(\theta_i - a\right)}{S\sqrt{\left[\left(F^T F\right)^{-1}\right]_{ii}}} \sim S(N-m)$ (розподіл Стьюдента з параметром *N-m*).

Нехай зафіксоване деяке число α, 0<α<1, яким визначається рівень довіри в процедурах перевірки H_0. Гіпотеза H_0 відкидається, якщо $|u|>|u_{\frac{\alpha}{2}}|$. $u_{\frac{\alpha}{2}}$ - $\alpha/2$ квантиль стандартного нормального розподілу; або $|t|>|t_{\frac{\alpha}{2}}|$. При цьому ймовірність, що H_0 буде відкинута при умові, що вона вірна, рівна α.

Приклад 1.9 (продовження прикладу 1.7)

Перевіримо гіпотезу $H_0 : \theta_1 = 0$ за результатами розрахунку параметрів регресії *1+2x*. Нехай α =0.05, σ^2=1.

1) $u = 1.07 / \sqrt{0.17} = 2.60$. $u_{\frac{\alpha}{2}}$=1.96. Отже, гіпотеза H_0 повинна бути відхилена.

2) Нехай σ^2 є невідомим. $t = 1.07 / S\sqrt{0.17}$=2.21. $|t_{\frac{\alpha}{2}}|$=2.78; тому гіпотеза повинна бути прийнятою.

1.7. узагальнений метод найменших квадратів.

Узагальненою лінійною регресійною моделлю називається модель $(Y, F\theta, \sigma^2 W)$, де W – відома додатньо визначена матриця, а параметр σ^2 може бути невідомим.

Типовою ситуацією використання узагальненої моделі є наступна: $y_j = \theta^T x_{(j)} + \varepsilon_j$, де $x_{(j)} = (x_{j1},...,x_{jm})^T$ - точки, в яких проводяться вимірювання, ε_j - некорельовані випадкові похибки з однаковою дисперсією σ^2. Нехай серед точок $x_{(j)}$ *(j=1,...,N)* тільки *M (M≤N)* є різними. Позначимо ці точки $\tilde{x}_{(1)},...,\tilde{x}_{(M)}$, а через r_l - кількість вимірів в точці $\tilde{x}_{(l)}$ ($r_l \geq 1$, $\sum_{l=1}^{M} r_l = N$).

Усереднюючи результати різних вимірів в точках $x_{(j)}$, отримаємо модель $\tilde{y}_l = \theta^T \tilde{x}_{(l)} + \varepsilon_l$, *l*=1,...,*M*, де $\tilde{y}_l$ - середнє арифметичне вимірів y_j в точках $\tilde{x}_{(l)}$, $\tilde{\varepsilon}_l$ - середнє арифметичне похибок, $E\tilde{\varepsilon}_l$=0; $M\tilde{\varepsilon}_l\tilde{\varepsilon}_k = \begin{cases} 0, l \neq k \\ \sigma^2/r_l, l = k \end{cases}$.

Перейдемо до розгляду узагальненої моделі. Оскільки *W*>0, то існує невироджена квадратна матриця V така, що $W = VV^T$. Поклавши $\tilde{Y} = V^{-1}Y$, $\tilde{F} = V^{-1}F$, $\tilde{\varepsilon} = V^{-1}\varepsilon$, помножимо $Y = F\theta + \varepsilon$ зліва на V^{-1}; отримаємо: $\tilde{Y} = \tilde{F}\theta + \tilde{\varepsilon}$, тобто модель $(Y, F\theta, \sigma^2 W)$ еквівалентна моделі $(\tilde{Y}, \tilde{F}\theta, \sigma^2 I_N)$, бо $D\tilde{\varepsilon} = M\tilde{\varepsilon}\tilde{\varepsilon}^T = V^{-1}\sigma^2 W\left(V^{-1}\right)^T = \sigma^2 V^{-1}VV^T\left(V^{-T}\right)^{-1} = \sigma^2 I_N$. МНК-оцінка для моделі $(\tilde{Y}, \tilde{F}\theta, \sigma^2 I_N)$ має вигляд $\hat{\theta} = \left(\tilde{F}^T\tilde{F}\right)^{-1}\tilde{F}^T\tilde{Y}$ = = $\left(F^T\left(VV^T\right)^{-1}F\right)^{-1}F^T\left(VV^T\right)^{-1}Y = \left(F^TW^{-1}F\right)^{-1}F^TW^{-1}Y$.

За означенням оцінку $\hat{\theta} = \left(F^TW^{-1}F\right)^{-1}F^TW^{-1}Y$ називають узагальненою МНК-оцінкою. Згідно з лемою 1.1 ця оцінка мінімізує вираз $\left(\tilde{Y} - \tilde{F}\theta\right)^T\left(\tilde{Y} - \tilde{F}\theta\right) = (Y - F\theta)^T W^{-1}(Y - F\theta)$.

Зокрема, якщо матриця W є діагональною, то такий вираз називають зваженою сумою квадратів відхилень.

Використовуючи лему 1.3, підрахуємо дисперсію МНК-оцінки.

$$D\hat{\theta} = \left(F^TW^{-1}F\right)^{-1}F^TW^{-1}DY\left[\left(F^TW^{-1}F\right)^{-1}F^TW^{-1}\right]^T = \quad =$$

$$\sigma^2\left(F^TW^{-1}F\right)^{-1}F^TW^{-1}WW^{-1}F\left(F^TW^{-1}F\right)^{-1} = \sigma^2\left(F^TW^{-1}F\right)^{-1}.$$

Отже, $D\hat{\theta} = \sigma^2\left(F^TW^{-1}F\right)^{-1}$.

Згідно з теоремою Гауса-Маркова узагальнена МНК-оцінка є НЛН-оцінкою для моделі $(\tilde{Y}, \tilde{F}\theta, \sigma^2 I_N)$, а отже, і для моделі $(Y, F\theta, \sigma^2 W)$.

Приклад 1.10. (продовження 1.7)

Прирустимо, що істинна функція регресії $\eta(x) = 1 + 2x$ і шість вимірів проводяться в точках $x_1 = -1$ ($r_1 = 3$), $x_2 = 0$ ($r_2 = 1$), $x_3 = 1$ ($r_3 = 2$).

Вважатимемо, що дисперсія вимірювань σ^2=1, а значення похибок такі ж, як і в 1.7: -0.49, 1.68, -0.06 (при вимірюванні в x_1), -0.49, 0.86 (в точці x_3), -1.23 (в точці x_2). Усереднюючи результати вимірювань отримаємо:

$$y_1 = -1 + \frac{1}{3}(-0.49 + 1.86 - 0.06) = -0.56$$

$$y_2 = 1 - 1.23 = -0.23$$

$$y_3 = 3 + \frac{1}{2}(-0.45 + 0.86) = 3.15.$$

Дисперсії похибок при вимірюванні y_1, y_2, y_3 рівні відповідно $\sigma^2/3$, σ^2, $\sigma^2/2$. Таким чином, в моделі $(Y, F\theta, \sigma^2 W)$ маємо: $Y = \begin{pmatrix} -0.56 \\ -0.23 \\ 3.19 \end{pmatrix}$,

$$F = \begin{pmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{pmatrix}, \; W = \begin{pmatrix} 1/3 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1/2 \end{pmatrix}. \; W^{-1} = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix},$$

$$F^T W^{-1} F = \begin{pmatrix} 1 & 1 & 1 \\ -1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 3 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 6 & -1 \\ -1 & 5 \end{pmatrix}$$

$$\left(F^T W^{-1} F\right)^{-1} = \begin{pmatrix} 5/29 & 1/29 \\ 1/29 & 6/29 \end{pmatrix}; \; \hat{\theta} = \begin{pmatrix} 1.05 \\ 1.82 \end{pmatrix}.$$

У припущенні що σ^2=1, перевіримо гіпотезу H_0: $\theta_2 = 2$.

$$D\hat{\theta}_2 = \sigma^2 \left[\left(F^T W^{-1} F\right)^{-1} \right]_{22} = \frac{6}{29} = 0.207.$$

$$|u| = \left| \frac{1.82 - 2}{\sqrt{0.207}} \right| = 0.4 < 1.96.$$

Отже, гіпотеза H_0 повинна бути прийнятою.

1.8. Наслідки невірного задання дисперсійної матриці похибок вимірів.

Припустимо, що для оцінки параметрів узагальненої лінійної регресійної моделі $(Y, F\theta, \sigma^2 W)$ використовується оцінка $\hat{\theta}(A) = \left(F^T A^{-1} F\right)^{-1} F^T A^{-1} Y$, де A>0 деяка матриця, що є наближенням W. Дана

оцінка є незміщеною, що легко перевірити. Дисперсія цієї оцінки $D\left(\hat{\theta}(A)\right)=\sigma^2\left(F^T A^{-1}F\right)^{-1}F^T A^{-1}WA^{-1}F\left(F^T A^{-1}F\right)^{-1}$.

Оскільки $\hat{\theta}(W)$ є НЛН оцінкою, то $D\left(\hat{\theta}(A)\right)\geq D\left(\hat{\theta}(W)\right)$. Втрата ефективності у випадку $A=I_N$ визначається формулою:

$$D\left(\hat{\theta}(I_N)\right)-D\left(\hat{\theta}(W)\right)=\sigma^2\left(UF^T-SF^TW^{-1}\right)W\left(FU-W^{-1}FS\right)= \quad =$$

$$\sigma^2\left(UF^TWFU-S\right)\geq 0,$$

де $S=\left(F^TW^{-1}F\right)^{-1}$; $U=\left(F^TF\right)^{-1}$.

Звідси зокрема випливає, що точність МНК-оцінки така ж, як і узагальненої тільки у випадку, якщо $UF^T=SF^TW^{-1}$.

Розглянемо тепер наслідки задання матриці $A=I_N$ замість W при оцінці σ^2 в моделі $(Y,F\theta,\sigma^2W)$ маємо $S^2=\hat{\varepsilon}^T\hat{\varepsilon}/(N-m)$, де $\hat{\varepsilon}=Y-FUF^TY=GY$. $G=I_N-FUF^T$; $G^2=G$, $trG=N-m$. Аналогічно, як при доведенні теореми 1.2, отримуємо $M\hat{\varepsilon}^T\hat{\varepsilon}==MY^TG^2Y=MY^TGY=M\left(F\theta+\varepsilon\right)^TG\left(F\theta+\varepsilon\right)=$ $\theta^TF^TGF\theta+M\hat{\varepsilon}^TG\hat{\varepsilon}==\theta^TF^TF\theta-\theta^TF^TF\theta=MtrG\varepsilon\varepsilon^T=trGM\varepsilon\varepsilon^T=\sigma^2trGW=$ $\sigma^2trW-\sigma^2trFUF^TW==\sigma^2\left[trW-tr\left(F^TWFU\right)\right]$.

Отже,

$$MS^2=\frac{M\hat{\varepsilon}^T\hat{\varepsilon}}{N-m}=\frac{\sigma^2\left[trG+trG\left(W-I_N\right)\right]}{N-m}=\sigma^2+\frac{\sigma^2}{N-m}trG\left(W-I_N\right)=$$

$$\sigma^2-\frac{\sigma^2}{N-m}\left[trF^TWFU-m\right].$$

І S^2 не є, взагалі кажучи, незміщеною оцінкою для σ^2.

1.9. Обчислення МНК-оцінок для моделей неповного рангу.

Кажуть, що лінійна регресійна модель $(Y,F\theta,\Sigma)$ має неповний ранг, якщо $rangF=p<m$, де m – кількість невідомих параметрів у моделі. Лінійні регресійні моделі неповного рангу часто виникають в задачах дисперсійного аналізу. Опишемо спосіб побудови МНК-оцінок для таких моделей, тобто розв'язку нормальної системи рівнянь

$$F^TF\theta=F^TY \tag{1.9.1}$$

Припустимо, що ранг матриці F^TF дорівнює p, $0\leq p\leq m$. Без обмеження загальності, можна вважати, що перші p стовпців $x_1,...,x_p$ $N\times m$ матриці F є лінійно незалежними. Позначимо $F_{(1)}=\left(x_1,...,x_p\right)$; $F_{(2)}=\left(x_{p+1},...,x_m\right)$, тоді $F=\left(F_{(1)},F_{(2)}\right)$, $\theta=\left(\theta_{(1)},\theta_{(2)}\right)^T$, $\theta_{(1)}=\left(\theta_1,...,\theta_p\right)^T$, $\theta_{(2)}=\left(\theta_{p+1},...,\theta_m\right)^T$.

Ранг матриці $F_{(1)} = p$, тому стовпці матриці $F_{(2)}$ лінійно залежать від стовпців $F_{(1)}$, тобто існує така $p \times (m-p)$ матриця L, що має місце зображення $F_{(2)} = F_{(1)}L$. Система нормальних рівнянь (1.9.1) запишеться у вигляді

$$\begin{pmatrix} F_{(1)}^T F_{(1)} & F_{(1)}^T F_{(1)} L \\ L^T F_{(1)}^T F_{(1)} & L^T F_{(1)}^T F_{(1)} L \end{pmatrix} \begin{pmatrix} \theta_{(1)} \\ \theta_{(2)} \end{pmatrix} = \begin{pmatrix} F_{(1)}^T Y \\ L^T F_{(1)}^T Y \end{pmatrix} \tag{1.9.2}$$

Перші p рядків цієї системи рівнянь мають вигляд

$$F_{(1)}^T F_{(1)} \theta_{(1)} + F_{(1)}^T F_{(1)} L \theta_{(2)} = F_{(1)}^T Y \tag{1.9.3}$$

решта m-p рівнянь (1.9.2) є лінійною комбінацією рівнянь (1.9.3); отже, довільний розв'язок системи (1.9.3) є розв'язком (1.9.1). Оскільки $rangF_{(1)} = p$, у матриці $F_{(1)}^T F_{(1)}$ існує обернена. Домножаємо (1.9.3) зліва на $\left(F_{(1)}^T F_{(1)}\right)^{-1}$;

$$\theta_{(1)} = \left(F_{(1)}^T F_{(1)}\right)^{-1} F_{(1)}^T Y - L\theta_{(2)} \tag{1.9.4}$$

Оскільки *(m-p)*-вимірний вектор $\theta_{(2)}$ може бути вибраним довільним чином, то формулою (1.9.4) визначається *(m-p)*-вимірний многовид розв'язків системи нормальних рівнянь (1.9.1).

<u>Приклад 1.11.</u>

Нехай функція регресії має вигляд: $\eta(x) = \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3$, а виміри проводяться в трьох точках $(1,-1,0)^T, (0,1,-1)^T$, $(-1,0,1)^T$. В моделі зважування трьох предметів на двошалькових терезах це відповідає тому, що при першому зваженні на лівій чашці був предмет А, на правій В і т. д. Матриця F має вигляд:

$$F = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \\ -1 & 0 & 1 \end{pmatrix}.$$

$$F^T F = \begin{pmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{pmatrix}; \; F^T Y = \begin{pmatrix} y_1 - y_3 \\ y_2 - y_1 \\ y_3 - y_2 \end{pmatrix};$$

$$\begin{cases} 2\theta_1 - \theta_2 - \theta_3 = y_1 - y_3, \\ -\theta_1 + 2\theta_2 - \theta_3 = y_2 - y_1, \\ -\theta_1 - \theta_2 + 2\theta_3 = y_3 - y_2. \end{cases}$$

Третє рівняння є наслідком перших двох.

$$\theta_2 = \frac{1}{3}\left(-y_1 + 2y_2 - y_3\right) + \theta_3,$$

$$\theta_1 = \frac{1}{3}\left(-2y_1 + 4y_2 - 2y_3 + 4\theta_3 - 3\theta_3 - 3y_2 + 3y_1\right) = \frac{1}{3}\left(y_1 + y_2 - 2y_3\right) + \theta_3.$$

Побудуємо МНК-оцінку, використовуючи розглядувану методику. $\theta_{(1)} = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$, $F_{(1)} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \\ -1 & 0 \end{pmatrix}$; $F_{(2)} = \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix} = F_{(1)}L$, де $L = \begin{pmatrix} -1 \\ -1 \end{pmatrix}$, тоді

$$F_{(1)}^T F_{(1)} = \begin{pmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 0 & 1 \\ -1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix},$$

$$\left(F_{(1)}^T F_{(1)}\right)^{-1} = \begin{pmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{pmatrix},$$

$$F_{(1)}^T Y = \begin{pmatrix} y_1 - y_3 \\ y_2 - y_1 \end{pmatrix}.$$

$$\theta_{(1)} = \begin{pmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{pmatrix} \begin{pmatrix} y_1 - y_3 \\ y_2 - y_1 \end{pmatrix} + \begin{pmatrix} \theta_3 \\ \theta_3 \end{pmatrix} = \begin{pmatrix} \frac{1}{3}(y_1 + y_2 - 2y_3) + \theta_3 \\ \frac{1}{3}(-y_1 + 2y_2 - y_3) + \theta_3 \end{pmatrix}.$$

Якщо $\hat{\theta}$ є оцінкою параметрів θ, то оцінкою вектора значень $F\theta$ є $F\hat{\theta}$. Покажемо, що МНК-оцінка вектора значень не залежить від вибору розв'язків системи нормальних рівнянь.

<u>Лема 1.5.</u>

Нехай $rangF = p \le m$. Якщо $\hat{\theta}^{(1)}$ і $\hat{\theta}^{(2)}$ - розв'язки системи (1.9.1), причому $\hat{\theta}^{(1)} \ne \hat{\theta}^{(2)}$, то $F\hat{\theta}^{(1)} = F\hat{\theta}^{(2)}$ і $Q\left(\hat{\theta}^{(1)}\right) = Q\left(\hat{\theta}^{(2)}\right)$, де $Q(\theta) = (Y - F\theta)^T (Y - F\theta)$.

Доведення.

Довільний розв'язок системи (1.9.1) $\hat{\theta} = \left(\hat{\theta}_{(1)}, \hat{\theta}_{(2)}\right)$, де $\hat{\theta}_{(2)}$ - довільний вектор, а $\hat{\theta}_{(1)}$ визначається за формулою (1.9.4). Тому

$$F\hat{\theta} = \left(F_{(1)}, F_{(1)}L\right) \begin{bmatrix} \left(F^T{}_{(1)}, F_{(1)}\right)^{-1} F_{(1)}^T Y - L\theta_{(2)} \\ \theta_{(2)} \end{bmatrix} = =$$

$$F_{(1)}\left(F_{(1)}, F_{(1)}\right)^{-1} F_{(1)}^T Y - F_{(1)}L\theta_{(2)} + F_{(1)}L\theta_{(2)} = F_{(1)}\left(F^T{}_{(1)}, F_{(1)}\right)^{-1} F_{(1)}^T Y.$$

Тобто $F\hat{\theta}$ однозначно визначається за матрицею плану і не залежить від $\hat{\theta}_{(2)}$.

<u>Зауваження.</u>

З цієї леми випливає, що довільний розв'язок системи (1.9.1) надає мінімум Q, і, отже, є МНК-оцінкою. Зворотнє твердження, а саме, що кожна МНК-оцінка є розв'язком системи (1.9.1) випливає з леми 1.1.

Іншим способом зображення розв'язків використовує так звані псевдообернені матриці.

Означення. Матриця A^{-} називається псевдооберненою, якщо $A = AA^{-}A$.

За допомогою псевдооберненої матриці розв'язок (1.9.1) може бути заданий $\hat{\theta} = \left(F^T F\right)^{-} F^T Y$.

Для випадку *rangF=p<m* незміщено оцінити всі невідомі параметри моделі $(Y, F\theta, \Sigma)$ неможливо, але можна оцінити деякі лінійні комбінації невідомих параметрів. Тобто параметричну функцію, що має вигляд $\tau = t^t\theta$, де t – m-вимірний вектор.

Означення. Параметрична функція $\tau = t^t\theta$ оцінювана, або є такою, що допускає оцінку, якщо для неї існує лінійна незміщена оцінка виду $\hat{\tau} = b^t Y$ $(b \in R^N)$.

Лема 1.6.

Для моделі $(Y, F\theta, \Sigma)$ параметрична функція $\tau = t^T\theta$ є оцінюваною тоді і тільки тоді, коли $t \in \mathcal{L}\left(F^T\right)$, де $\mathcal{L}\left(F^T\right)$ - сукупність всіх лінійних комбінацій стовпців матриці F^T.

Доведення.

Так як $\hat{\tau} = b^T Y$, то для всіх θ маємо

$t^T\theta = M\hat{\tau} = Mb^T Y = b^T F\theta$. Повторюючи доведення леми 1.2 робимо висновок, що $t^T = b^T F$, або $t^T = F^T b$. Лема доведена.

Сформулюємо деякі властивості параметричних функцій у вигляді теореми.

Теорема 1.4.

Нехай задана модель $(Y, F\theta, \sigma^2 I_N)$, *rangF=p*$\le m$ і $\hat{\theta}$ - довільний рзв'язок системи нормальних рівнянь (1.9.1). Тоді, якщо параметрична функція $\tau = t^T\theta$ є оцінюваною, то

1) Вигляд оцінки $t^T\hat{\theta}$ не залежить від вибору розв'язку системи нормальних рівнянь.
2) $t^T\hat{\theta}$ є НЛН-оцінкою τ.

Доведення.

Нехай $\tau = t^T\theta$ є оцінюваною. Тоді із леми 1.6 випливає існування вектора $b \in R^N$, для якого $t^T = b^T F$, звідки $t^T\hat{\theta} = b^T F\hat{\theta}$. І, за лемою 1.5, права частина визначена однозначно. Твердження 2) теореми 1.4 доводиться аналогічно до теореми 1.1.

Доведена теорема легко узагальнюється на той випадок,коли необхідно оцінити векторну параметричну функцію $\tau = T\theta$, де T $q \times m$- матриця, рядки якої є лінійними комбінаціями рядків матриці F (у цьому випадку, як випливає з леми 1.6, існує лінійна незміщена оцінка для τ, тобто τ є оцінюваною функцією).

Теорема 1.5

Нехай задана модель $(Y, F\theta, \sigma^2 I_N)$, $rangF=p\le m$ і $\hat{\theta}$ - довільний розв'язок системи нормальних рівнянь (1.9.1). Тоді, якщо векторна параметрична функція $\tau = T^T\theta$ є оцінюваною, то оцінка $\hat{\tau} = T^T\hat{\theta}$ визначається єдиним чином і є НЛН-оцінкою τ.

Доведення теореми повторює доведення тореми 1.4.

1.10. Зміщене лінійне оцінювання

МНК-оцінка $\hat{\theta}$ є найкращою в класі лінійних незміщених оцінок Ξ. Якщо відмовитись від умови незміщеності, то можна отримати оцінки, які в ряді випадків мають деякі переваги у порівнянні з МНК-оцінками.

Розглянемо невироджену модель $(Y, F\theta, \sigma^2 I_N)$. Виконаємо деякі перетворення над функцією $Q(\theta)$.

$$Q(\theta) = (Y - F\theta)^T (Y - F\theta) = \left[Y - F\hat{\theta} - F\left(\theta - \hat{\theta}\right)\right]^T \times \left[Y - F\hat{\theta} - F\left(\theta - \hat{\theta}\right)\right] = =$$

$$\left(Y - F\hat{\theta}\right)^T \left(Y - F\theta\right) - \left(Y - F\hat{\theta}\right)^T F\left(\theta - \hat{\theta}\right) - \left(\theta - \hat{\theta}\right)^T F^T \left(Y - F\hat{\theta}\right) + \qquad +$$

$$\left(\hat{\theta} - \theta\right)^T F^T F \left(\hat{\theta} - \theta\right) \equiv Q_{\min} + \alpha(\theta).$$

де $Q_{\min} = Q\left(\hat{\theta}\right)$, $\alpha(\theta) = \left(\hat{\theta} - \theta\right)^T F^T F \left(\hat{\theta} - \theta\right)$.

Нехай $\alpha_0 > 0$ деяке задане число. Існує многовид векторів θ, які задовільняють співвідношення

$$Q(\theta) = Q_{\min} + \alpha_0 \qquad (1.10.1)$$

Поставимо задачу знаходження мінімуму функціоналу $f(\theta) = \theta^T\theta$ при умові (1.10.1). Для розв'язання цієї задачі на умовний екстремум використаємо метод множників Лагранжа. Нехай $R(\theta) = f(\theta) + \lambda Q(\theta)$, $\lambda = 1/k$ відповідно функція Лагранжа і множник Лагранжа для даної задачі. І ми приходимо до задачі на безумовний екстремум для функції $R(\theta) = \theta^T\theta + \left(1/k\right)\left[\left(\theta^T - \theta\right)^T F^T F\left(\hat{\theta} - \theta\right) - \alpha_0\right]$, необхідною умовою (а в даному випадку і достатньою, в силу того, що $R(\theta)$ додатньо визначена квадратична форма: α_0 віддаляє значення $Q(\theta)$ від 0) є $\nabla R(\theta) = 0$.

Позначимо елементи матриці $F^T F$ m_{ij} *(i,j=1,...,m),* зауважимо, що $m_{ij} = m_{ji}$. Маємо

$$\frac{\partial R}{\partial \theta_e} = \frac{\partial}{\partial \theta_e}\sum_{i=1}^{m}\theta_i^2 + \frac{1}{k}\frac{\partial}{\partial \theta_l}\sum_{i,j=1}^{m}\left(\theta_i - \hat{\theta}_i\right)m_{ij}\left(\theta_j - \hat{\theta}_j\right) =$$

$$= 2\theta_e + \frac{1}{k}\frac{j}{\partial \theta_e}\sum_{i=1}^{m}(\theta_i - \hat{\theta}_i)^2 m_{ij} + \frac{1}{k}\frac{j}{\partial \theta_e}\sum_{i\neq j}^{m}(\theta_i - \hat{\theta}_i)^2 m_{ij} - (\theta_i - \hat{\theta}_j) \quad =$$

$$2\theta_e + \frac{1}{k}2m_{ll}\left(\theta_l - \hat{\theta}_l\right) + \frac{2}{k}\sum_{\substack{i=1\\ i\neq l}}^{m}\left(\theta_i - \hat{\theta}_i\right)m_{il} \;=\; 2\left[\theta_e + \frac{1}{k}\sum_{i=1}^{m}\left(\theta_i - \hat{\theta}_i\right)m_{il}\right].$$

Отже, $\nabla R(\theta) = 2\left[\theta + \frac{1}{k}F^T F(\theta - \hat{\theta})\right]$.

Із вигляду МНК-оцінки маємо $F^T F\hat{\theta} = \left(F^T F\right)\left(F^T F\right)^{-1}F^T Y = F^T Y$ і система $\nabla R = 0$ запишеться у вигляді

$$\theta + \frac{1}{k}F^T F\theta = \frac{1}{k}F^T Y$$

$$\left(kI_m + F^T F\right)\theta = F^T Y \qquad (1.10.2)$$

$$\hat{\theta}(k) = \left(kI_m + F^T F\right)^{-1}F^T Y \qquad (1.10.3)$$

$\hat{\theta}$ визначена за формулою (1.10.3) і є розв'язком (1.10.2). $\hat{\theta}$ (1.10.3) називають гребеневою оцінкою. Значення k однозначно пов'язане з α_0 співвідношенням $Q\left(\hat{\theta}(k)\right) = Q_{\min} + \alpha_0$.

При малих k оцінки $\hat{\theta}(k)$ і $\hat{\theta}$ майже співпадають; $\hat{\theta}(k) \to \hat{\theta}$ при $k \to 0$ за ймовірністю.

Переваги гребеневих оцінок по відношенню до МНК виявляються у випадках, коли $F^T F$ є погано обумовленою. Крім того, незалежно від того, чи вироджена модель, гребенева оцінка визначається однозначно.

Іншим поширеним способом задавання зміщених оцінок є такий. Розглядаються оцінки $\tilde{\theta}(\alpha) = \alpha\hat{\theta}$, де $\hat{\theta}$ - стандартна МНК-оцінка $0 < \alpha < 1$

Для невиродженої класичної лінійної регресійної моделі $(Y, F\theta, \sigma^2 I_N)$ для всіх $\hat{\theta}$ маємо $M\tilde{\theta}(\alpha) = \alpha M\hat{\theta} = \alpha\theta$; а $D\tilde{\theta}(\alpha) = \alpha^2 D\hat{\theta}$. Таким чином, $\tilde{\theta}$ є зміщеною, але дисперсійна матриця $D\tilde{\theta}$ завжди є меншою,ніж $\Delta\hat{\theta}$. Отже, розумний вибір α дозволяє за рахунок деякого зміщення зменшити дисперсії і коваріації оцінок.

Оцінки $\tilde{\theta}(\alpha)$ в літературі носять назву Джеймса-Стейна, або стискаючих оцінок.

§2. Лінійний регресійний аналіз при наявності апріорної інформації про параметри.

2.1. Основні види апріорної інформації про параметри.

Узагальнена МНК-оцінка є НЛН-оцінкою для моделі $(Y, F\theta, \sigma^2 W)$, при цьому джерелом інформації про невідомі параметри є результати вимірів Y і вигляд регресійної моделі.

Часто в наявності у дослідника є додаткова інформація про параметри моделі. Вміле врахування такої інформації дозволяє побудувати лінійні оцінки, які володіють кращими властивостями, ніж МНК-оцінки.

Найпростішим видом апріорної інформації про параметри є обмеження типу нерівностей. В цьому випадку задача оцінювання параметрів легко зводиться до стандартної. Складнішим є випадок, коли апріорна інформація про параметри моделі задається у вигляді нерівностей. Припустиме, що обмеження, які задають параметричну множину Ω, визначаються такою множиною точок $\Omega \equiv \{\theta \in R^m \mid (\theta - \theta_0)^T B(\theta - \theta_0) \le k\}$, де B>0 – задана матриця, $\theta_0 \in R^m$ - центр еліпсоїда, деяка фіксована точка, k>0 – числовий параметр. В описуваному випадку апріорна інформація полягає в тому, що $\theta \in \Omega$. При такій апріорній інформації найбільш природнім виявляється мінімаксний підхід.

В деяких випадках додаткова інформація про параметри моделі $(Y, F\theta, \sigma^2 W)$ може бути поданою у вигляді $r = R\theta + \varphi$, $\varphi \sim N(0, V)$, V>0, $M\varphi\varepsilon^T = 0$, де r – невідомий вектор висоти l, R – фіксована $l \times m$ матриця, V – відома $l \times l$ матриця. В цьому випадку r відіграє роль вектора спостережень в лінійній регресійній моделі $(r, R\theta, V)$, φ - вектор похибок вимірів, причому вектори φ і ε некорельовані. Апріорна інформація такого вигляду зустрічається в тому випадку, коли у дослідника є додаткова інформація про дану або аналогічну модель і коли вже була зроблена попередня оцінка $\tilde{\theta}$ всіх невідомих параметрів (в цьому випадку $r = \tilde{\theta}$, $R = I_m$, $l = m$) або їх частини.

Можна також припускати, що на σ-алгебрі підмножин множини Ω заданий апріорний розподіл з деяким вектором матсподівань і дисперсійною матрицею. Буде показано, що і в цьому випадку задача зводиться до класичної. Таким чином, ми розглядатимемо тільки ті види апріорної інформації про параметричну область, врахування якої може бути здійснено достатньо ефективно.

2.2 Лінійні обмеження на параметри.

Нехай в рамках схеми $(Y, F\theta, \sigma^2 W)$ є обмеження на параметри θ, задані у вигляді співвідношень $R\theta = r$, де R - це $q \times m$ матриця, $rangq=r$ (0<q<m), а r – деякий q вектор. Як відомо, загальний розв'язок такої системи рівнянь може бути записаний у вигляді $\theta = \theta_0 + B\beta$, де θ_0 - розв'язок (частинний), β - довільний (m - q) -вектор, а B – матриця $m \times (m - q)$, $rangB=m-q$. Зробимо заміну $Z = Y - F\theta_0$, тоді $MZ = MY - F\theta_0 = F(\theta_0 + B\beta) - F\theta_0 = FB\beta$.

Отже, дана модель еквівалентна $(Z, FB\beta, \sigma^2 W)$, в якій роль вектора вимірів відіграє вектор $Z = Y - F\theta_0$, а новими параметрами є β. Незміщена

оцінка може бути знайдена у випадку, коли матриця FB має повний ранг.

Оцінкою параметрів θ є $\hat{\theta} = \theta_0 + B\hat{\beta}$, де $\hat{\beta}$ - оцінка для β.

2.3. Мінімаксне оцінювання.

Нехай $a \in R^m$ - фіксований вектор, причому $a \not\equiv 0$. Запишемо функцію

$$r(\theta, \tilde{\theta}) \equiv r(\theta, \tilde{\theta}, a) = a^T M(\tilde{\theta} - \theta)(\tilde{\theta} - \theta)^T a \qquad (2.3.1)$$

Функція r залежить від параметрів θ, їх оцінок $\tilde{\theta}$, вектора $a \in R^m$. Якість оцінки в даному пункті будемо вимірювати величиною $\max\limits_{\theta \in \Omega} r(\theta, \tilde{\theta})$.

<u>Означення.</u> Лінійна відносно вимірів оцінка $\hat{\theta}_{(M)} = \arg\min\limits_{\tilde{\theta} \in \Omega} \left[\max\limits_{\theta \in \Omega} r(\theta, \tilde{\theta}) \right]$ називається мінімаксною.

<u>Теорема 2.1.</u>

Нехай задана $(Y, F\theta, \sigma^2 W)$ схема регресії і параметрична множина $\Omega = \{\theta \mid (\theta - \theta_0)^T B(\theta - \theta_0) \le k\}$, тоді мінімаксна оцінка визначається формулою

$$\hat{\theta}_{(M)} = \left[\frac{\sigma^2}{k} B + F^T W^{-1} F \right]^{-1} F^T W^{-1} (Y - F\theta_0) + \theta_0 \qquad (2.3.2)$$

Доведення.

Без обмеження загальності покладемо $\theta_0 = 0$ (інакше робимо заміну $\theta - \theta_0$ з відповідними змінами в формулах для оцінок). Для довільної однорідної оцінки $\tilde{\theta} = CY$ матимемо:

$$\tilde{\theta} - \theta = (CF - I_m)\theta + C\varepsilon,$$

$$r(\theta, \tilde{\theta}, a) = \sigma^2 a^T CWC^T a + \theta^T B^{1/2} \tilde{a}\tilde{a}^T B^{1/2} \theta, \qquad (2.3.3)$$

де симетрична $m \times m$ матриця $B^{1/2}$ задовільняє умові $\left(B^{1/2}\right)^2 = B$. $\tilde{a} = \left(B^{1/2}\right)^{-1} (CF - I_m)^T a$.

Для довільної квадратної матриці A:

$$\max_{\theta \ne 0} \left(\theta^T B^{1/2} A B^{1/2} \theta\right) / \left(\theta^T B \theta\right) = \lambda_{\max}(A), \qquad (2.3.4)$$

де $\lambda_{\max}(A)$ - найбільше власне значення матриці A.

Застосовуючи (2.3.4) до (2.3.3) при $A = \tilde{a}\tilde{a}^T$ отримаємо

$$\max_{\theta^T B \theta \le k} r(\theta, \tilde{\theta}, a) = \sigma^2 a^T CWC^T a + k\lambda_{\max}(A) \equiv \mathrm{J(C)}.$$

Оскільки $A = \tilde{a}\tilde{a}^T$, $\lambda_{\max}(A) = \tilde{a}^T \tilde{a}$ і, отже,

J(C)= $\sigma^2 a^T CWC^T a + k a^T (CF - I_m) B^{-1} (CF - I_m)^T a$.

Знайдемо похідну по C:

$$\frac{\partial \mathrm{J}}{\partial \mathrm{C}} = 2\left[\left(\sigma^2 W + kFB^{-1}F^T\right) C^T a a^T - kFB^{-1} a a^T\right] \qquad (2.3.5)$$

Зауважимо, що похідна береться по матриці C, тобто $\frac{\partial J}{\partial C}$ - матриця, яка складається з похідних J по відповідних елементах C. Прирівнюючи (2.3.5) до нуля, знайдемо

$$C_* = kB^{-1}F^T\left(\sigma^2 B + kFB^{-1}F^T\right)^{-1}.$$

Перетворимо дану оцінку:

$$\left(\sigma^2 W + kF^T W^{-1}F\right)C_* = k\sigma^2 F^T W^{-1} W\left(\sigma^2 W + kF^T W^{-1}F\right)^{-1} +$$

$$kF^T W^{-1}\left(kFB^{-1}F^T\right)\left(\sigma^2 W + kF^T W^{-1}F\right)^{-1} = kF^T W^{-1}.$$

З отриманого співвідношення випливає (2.3.2) з $\theta_0 = 0$. Теорема доведена.

Важливою властивістю мінімаксної оцінки (2.3.2) є те, що її вигляд не залежить від вектора a. Зокрема, у випадку $\theta_0 = 0$, $W = I_N$ мінімаксна оцінка має вигляд

$$\hat{\theta}_{(M)} = \left[\frac{\sigma^2}{k}B + F^T F\right]^{-1} F^T Y \qquad (2.3.6)$$

Отже, мінімаксна оцінка є гребеневою, при наявності апріорної інформації вигляду $\theta^T\theta \le \sigma^2/k$. При великих k (тобто при малості апріорної інформації) оцінка (2.3.6) прямує при $k \to 0$ до МНК-оцінки. Тобто МНК-оцінка є мінімаксною, якщо апріорна інформація є відсутньою.

<u>Теорема 2.2.</u>

В класі Ξ лінійних незміщених оцінок узагальнена МНК-оцінка $\left[\hat{\theta} = \left(F^T W^{-1}F\right)^{-1} F^T W^{-1} Y\right]$ є мінімаксною.

Доведення.

Із умови незміщеності оцінки $\tilde{\theta} = CY$ маємо $CF = I_m$, тому $\tilde{a} = 0$ і $\max\limits_{\theta^T\theta \le k} r\left(\theta, \tilde{\theta}, a\right) = \sigma^2 a^T CWC^T a = aD\tilde{\theta}a$. Згідно з результатами пункту 1.7, мінімум останнього виразу для довільного $a \in R^m$ досягається при $C = \left(F^T W^{-1}F\right)^{-1} F^T W^{-1}$. Теорема доведена.

2.4. Змішане оцінювання.

Змішаною моделлю назвемо модель $(Y, F\theta, \sigma^2 W)$ при наявності апріорної інформації вигляду $r = R\theta + \varphi$, $\varphi \sim (0, V)$, $V>0$, $M\varphi\varepsilon^T = 0$. Змішану модель записуємо у вигляді $(\tilde{Y}, \tilde{F}\theta, \sigma^2\tilde{W})$, де

$$\tilde{Y} = \begin{pmatrix} Y \\ r \end{pmatrix},\ \tilde{F} = \begin{pmatrix} F \\ R \end{pmatrix},\ \tilde{W} = \begin{pmatrix} W & 0 \\ 0 & \sigma^2 V \end{pmatrix}.$$

Застосовуючи результати пункту 1.7 для моделі $(\tilde{Y}, \tilde{F}\theta, \sigma^2\tilde{W})$, отримуємо

$$\hat{\theta}\left(\sigma^2\right) = \left(\tilde{F}^T\tilde{W}^{-1}\tilde{F}\right)^{-1}\tilde{F}^T\tilde{W}^{-1}\tilde{Y} = \left(\sigma^{-2}F^T W^{-1}F + R^T V^{-1}R\right)^{-1} \times \qquad (2.4.1)$$

$$\times\left(\sigma^{-2}F^{T}W^{-1}Y+R^{T}V^{-1}r\right)$$

і є НЛН оцінкою для змішаної моделі. Оскільки σ^2 є невідомим, то невизначена і $\hat{\theta}\left(\sigma^2\right)$. Якщо $V=\dfrac{\sigma^2}{R}W$, то

$$\hat{\theta}=\left(F^{T}W^{-1}F+kR^{T}V^{-1}R\right)^{-1}*\left(F^{T}W^{-1}Y+kR^{T}V^{-1}r\right). \qquad (2.4.2)$$

На практиці σ^2 замінюють оцінкою S^2.

2.5. Оцінювання за методикою Байєса.

Нехай на σ-алгебрі підмножин Ω задано розподіл $P(d\theta)$ із вектором середніх r і дисперсійною матрицею V, незалежний від розподілу ε, тобто $r=\int\limits_{\Omega}\theta P(d\theta)$, $V=\int\limits_{\Omega}(\theta-r)(\theta-r)^{T}P(d\theta)$, і нехай цей розподіл відображає апріорні відомості про θ. В цьому випадку апріорна інформація може бути записана у вигляді $(r,I_m\theta,V)$ і

$$\hat{\theta}\left(\sigma^2\right)=\left(\sigma^{-2}F^{T}W^{-1}F+V^{-1}\right)^{-1}\times\left(\sigma^{2}F^{T}W^{-1}Y+V^{-1}r\right) \qquad (2.5.1)$$

є НЛН оцінкою, яку називають її Байєсовою оцінкою. У випадку $W=I_N$, $V=I_m$, r=0 оцінка (2.5.1) співпадає з гребеневою оцінкою. Отже, гребенева оцінка є байєсовою для класичної лінійної регресійної моделі при наявності апріорної інформації вказаного вигляду з r=0, $V=I_m$.

§3. Основні поняття дисперсійного аналізу.

3.1. F-критерій для перевірки лінійних гіпотез про параметри лінійної регресії.

Припустимо, що в схемі лінійної регресії $\left(Y, F\theta, \sigma^2 I_N\right)$ вектор вимірів розподілений за нормальним законом

$$Y \sim N\left(F\theta, \sigma^2 I_N\right), \qquad (3.1.1)$$

а матриця $F^T F$ має не обов'язково повного рангу. Нехай T – матриця розміру $k \times m$, $rangT=k<m$ і рядки матриці T – лінійні комбінації рядків матриці F, тобто існує така матриця L розміру $k \times N$, що $T=LF$. Тоді за лемою 1.6 k параметричних функцій $t_i\theta$ $(i=1,\ldots,k)$ є такими, що допускають оцінку, тут $t_1,\ldots,t_k$ - рядки матриці T. позначимо $\hat{\tau}$ МНК-оцінку параметричної функції $\tau = T\theta$. За теоремою 1.5 $\hat{\tau} = T\hat{\theta}$, де $\hat{\theta} = \left(F^T F\right)^- F^T Y$. За лемою 1.5 *залишкова сума квадратів* $R_0^2 = \left(Y - F\hat{\theta}\right)^T \left(Y - F\hat{\theta}\right)$ визначається однозначно. Те ж саме стосується оцінки $\hat{\tau} = T\hat{\theta}$.

Перевіримо, чи випадкові величини R_0^2 і $\hat{\tau}$ незалежні.

<u>Теорема 3.1.</u>

Для схеми нормальної регресії $(Y, F\theta, \sigma^2 I_N), де Y \sim N\left(F\theta, \sigma^2 I_N\right)$,у випадку $T=LF$ статистики R_0^2 і $\hat{\tau}$ є незалежними.

Доведення.

$R_0^2 = \left(Y - F\hat{\theta}\right)^T \left(Y - F\hat{\theta}\right) = Y^T Y - Y^T F\hat{\theta} - \hat{\theta}^T F^T Y + \hat{\theta}^T F^T F\hat{\theta} = =$
$Y^T Y - Y^T F\left(F^T F\right)^- F^T Y - Y^T F\left(F^T F\right)^- F^T Y + Y^T F\left(F^T F\right)^- F^T F\left(F^T F\right)^- F^T Y = =$
$Y^T Y - Y^T F(F^T F) - F^T Y = Y^T\left(I_N - F\left(F^T F\right)^- F^T\right)Y$.

$\hat{\tau} = T\hat{\theta} = LF\left(F^T F\right)^- F^T Y$.

Отже, $R_0^2 = Y^T AY$; $\hat{\tau} = BY$; $A = I_N - F\left(F^T F\right)^- F^T$; $B = LF\left(F^T F\right)^- F^T$.

Перевіримо, чи BA=0.

Дійсно, $BA = LG\left(F^T F\right)^- F^T$, де $G = F - F\left(F^T F\right)^- F^T F$.

Підрахуємо $G^T G = \left(F^T - F^T F\left(F^T F\right)^- F^T\right)\left(F - F\left(F^T F\right)^- F^T F\right) =$
$F^T F - F^T F\left(F^T F\right)^- F^T F$ - $F^T F\left(F^T F\right)^- F^T F$ + $F^T F\left(F^T F\right)^- F^T F\left(F^T F\right)^- F^T F = 0$
$\Rightarrow G = 0$, отже, BA=0.

Покажемо, що із умови BA=0, випливає незалежність лінійної $\hat{\tau}$ і квадратичної R_0^2 форм. Скористаємося теоремою розкладу $A = \sum_{i=1}^{N} \lambda_i P_i P_i^T$, де λ_i - власні значення, а P_i - відповідні їм ортонормовані власні вектори матриці A. Тепер з умови BA=0 випливає, що BP_i=0 ($i=1,\ldots,N$), тому вектор BY є некорельований з випадковими величинами $P_i^T Y$ і не залежить від них.

$R_0^2 = Y^T AY = \sum_{i=1}^{N} \lambda_i \left(P_i^T Y\right)^2$ - з даного зображення і випливає твердження теореми.

Лема 3.1.

Нехай задано схему лінійної регресії (3.1.1), тоді

$$\hat{\tau} \sim N\left(T\theta, \sigma^2 T\left(F^T F\right)^{-} T^T\right) \qquad (3.1.2)$$

де $\hat{\tau}$ - МНК-оцінка векторної параметричної функції $\tau = T\theta$, T – матриця, для якої справедливе зображення $T=LF$.

Доведення.

Оскільки випадковий вектор Y розподілений за нормальним законом, то випадковий вектор $\hat{\tau}$ теж розподілений за тим же законом. Знайдемо параметри цього закону.

$$M\hat{\tau} = MT\hat{\theta} = MT\left(F^T F\right)^{-} F^T Y = LF\left(F^T F\right)^{-} F^T F\theta .$$

При доведенні теореми 3.1 було показано, що матриця $G \equiv F - F\left(F^T F\right)^{-} F^T F$ складається з нулів, тобто $F = F\left(F^T F\right)^{-} F^T F$, отже, $M\hat{\tau} = LF\theta = T\theta$.

Обчислимо дисперсійну матрицю, використовуючи лему 1.3.

$$D\hat{\tau} = DLF\hat{\theta} = DLF\left(F^T F\right)^{-} F^T Y = LF\left(F^T F\right)^{-} F^T [DY] F\left(F^T F\right)^{-} F^T L^T =$$

$$\sigma^2 LF\left(F^T F\right)^{-} F^T F\left(F^T F\right)^{-} F^T L^T = \sigma^2 T\left(F^T F\right)^{-} T^T .$$

Отже, $D\hat{\tau} = \sigma^2 T\left(F^T F\right)^{-} T^T$. Лема доведена.

Лема 3.2.

Для схеми регресії (3.1.1), в якій матриця F розміру $N \times m$ має ранг $r \le m$ статистика $\sigma^{-2} R_0^2$ розподілена за χ^2 з N-r степенями вільності, тобто $R_0^2 \sim \sigma^2 \chi^2 (N - r)$.

Доведення.

При доведенні теореми 3.1 для залишкової суми квадратів було отримане зображення $R_0^2 = Y^T AY$, де $A = I_N F\left(F^T F\right)^{-} F^T$. Так як Y розподілений за нормальним законом, а R_0^2 - квадратична форма відносно Y, то $\mathrm{R}_0^2 \sim \sigma^2 \chi^2 (trA)$. Підрахуємо trA.

$$trA = tr\left(I_N - F\left(F^T F\right)^{-} F^T\right) = trI_N - trF\left(F^T F\right)^{-} F^T .$$

Згідно з лемою 1.5 матриця $F\left(F^T F\right)^{-} F^T$ визначається однозначно і не залежить від вибору способу знаходження і зображення узагальненої оберненої матриці. $trF\left(F^T F\right)^{-} F^T = trF^T F\left(F^T F\right)^{-} = trF^T F = rangF^T F = rangF = r$. Лема доведена.

Задача перевірки загальних лінійних гіпотез про параметри лінійної регресії формулюється таким чином. Нехай задано схему регресії (3.1.1), де матриця F, розміру $N \times m$, має ранг $r \le m < N$; Матриця T, розміру $k \times m$, має

ранг k ($k \le r$) і допускає зображення $T=LF$. Загальну лінійну гіпотезу про параметри моделі (3.1.1) запишемо у вигляді

$$H_0 : T\theta = \tau_0 \qquad (3.1.3)$$

Де τ_0 - деякий фіксований вектор висоти k.

Для МНК-оцінки $\hat{\tau}$ векторної параметричної функції $\tau = T\theta$ виконуються умови Леми 3.1, тобто $\hat{\tau} \sim N\left(T\theta, \sigma^2 T\left(F^T F\right)^{-} T^T\right)$.

$$\left(\hat{\tau} - \tau_0\right)^T \left[T\left(F^T F\right)^{-} T^T\right]^{-1} \left(\hat{\tau} - \tau_0\right) \sim \sigma^2 \chi^2(k).$$

При справедливості гіпотези (3.1.3) статистика

$$\mathcal{F} = \frac{\left(\hat{\tau} - \tau_0\right)^T V^{-1} \left(\hat{\tau} - \tau_0\right)}{k} \Bigg/ \frac{R_0^2}{N-r} \sim F(k, N-r),$$

тобто розподілена за законом Фішера з k, N-r степенями вільності, де матриця V визначається за формулою $V = T\left(F^T F\right)^{-} T^T$.

З'ясуємо тенденцію поведінки статистики $\mathcal{F}$ у випадку, коли гіпотеза H_0 є невірною. Маємо

$$M\frac{\left(\hat{\tau} - \tau_0\right)^T V^{-1} \left(\hat{\tau} - \tau_0\right)}{k} = \frac{1}{k} trV^{-1} M\left(\hat{\tau} - \tau + \tau - \tau_0\right)\left(\hat{\tau} - \tau + \tau - \tau_0\right)^T =$$

$$= \frac{1}{k} trV^{-1}\left[M\left(\hat{\tau} - \tau\right)\left(\hat{\tau} - \tau\right)^T + \left(\tau - \tau_0\right)\left(\tau - \tau_0\right)^T\right] = \frac{1}{k} trV^{-1}\left[\sigma^2 V + \left(\tau - \tau_0\right)\left(\tau - \tau_0\right)^T\right] =$$

$$\frac{\sigma^2}{k} trI_k + \frac{1}{k}\left(\tau - \tau_0\right)^T V^{-1}\left(\tau - \tau_0\right) = \sigma^2 + \frac{1}{k}\left(\tau - \tau_0\right)^T V^{-1}\left(\tau - \tau_0\right).$$

Отже, рівність $M\frac{\left(\hat{\tau} - \tau_0\right)^T V^{-1}\left(\hat{\tau} - \tau_0\right)}{k} = \sigma^2$ справджується тільки у випадку справедливості гіпотези H_0. Оскільки $\left(\tau - \tau_0\right)^T V^{-1}\left(\tau - \tau_0\right) > 0 \;\; \forall \tau \ne \tau_0$, то при виконанні гіпотези H_0 правильною є нерівність $M\frac{\left(\hat{\tau} - \tau_0\right)^T V^{-1}\left(\hat{\tau} - \tau_0\right)}{k} > \sigma^2$, причому чим більше τ відрізняється від τ_0, тим більшою є різниця між лівою і правою частинами. З іншого боку, незалежно від того,чи справедливою є гіпотеза H_0, виконується рівність $M\frac{R_0^2}{N-r} = \sigma^2$.

Таким чином, при виконанні гіпотези H_0 чисельник статистики $\mathcal{F}$ є більший за знаменник, причому величина перевищення залежить від того, наскільки величина перевищення залежить від того, наскільки τ далеко від τ_0. Отже, великі значення статистики $\mathcal{F}$ свідчать про те, що вибіркові дані суперечать гіпотезі H_0.

Якщо при заданому α знайти величину $\mathcal{F}_\alpha$ з умови $P(\mathcal{F} > \mathcal{F}_\alpha) = \alpha$, де $\mathcal{F} \sim F(k, N-r)$, то виконання нерівності $\mathcal{F}_{cn} < \mathcal{F}_\alpha$ трактуємо як те, що вибіркові дані не протирічать гіпотезі H_0, тобто гіпотезу H_0 слід прийняти. Інакше гіпотезу слід відхилити.

Розглянемо процедуру знаходження статистики $\mathcal{F}$, яка не потребує знаходження МНК-оцінок параметричної функції $\tau = T\theta$. Згадана процедура використовує таку лему:

Лема 3.3

Нехай задано схему регресії $\left(Y, F\theta, \sigma^2 I_N\right)$ і $(k \times m)$-матриця T допускає зображення $T=LF$. Тоді $(\hat{\tau}-\tau)^T V^{-1}(\hat{\tau}-\tau) = R_1^2 - R_0^2$, де $\hat{\tau}$ - МНК-оцінка параметричної функції $T\theta$, матриця $V = T\left(F^T F\right)^{-} T^T$ і $R_1^2 = \min\limits_{\theta: T\theta=\tau_0} (Y - F\theta)^T (Y - F\theta)$, τ_0 - фіксований вектор, $\tau_0 \in R^k$.

Доведення.

Застосуємо метод множників Лагранжа до задачі знаходження мінімуму R_1^2, розглянемо функцію

$$U = (Y - F\theta)^T (Y - F\theta) + \lambda(T\theta + \tau_0).$$

Необхідні умови екстремуму для функції U дають:

$$\begin{cases} F^T F\theta + T^T \lambda = F^T Y \\ T\theta = \tau_0 \end{cases}.$$

Нехай λ_*, θ_* - розв'язок системи. Перетворимо R_1^2:

$$R_1^2 = (Y - F\theta_*)^T (Y - F\theta_*) = \left(Y - F\hat{\theta}\right)^T \left(Y - F\hat{\theta}\right) + \left(\hat{\theta} - \theta_*\right)^T F^T F\left(\hat{\theta} - \theta_*\right),$$

де через $\hat{\theta} = \left(F^T F\right)^{-} F^T Y$ позначимо МНК-оцінку параметрів θ. Для встановлення потрібного зображення достатньо показати, що $\left(\hat{\theta} - \theta_*\right)^T F^T F\left(\hat{\theta} - \theta_*\right) = (\hat{\tau} - \tau_0)^T V^{-1}(\hat{\tau} - \tau_0)$.

Так як $T=LF$, то знайдеться матриця C така, що $T = CF^T F$, де C - $k \times m$ матриця і $F^T F\left(\hat{\theta} - \theta_*\right) = T^T \lambda_* = F^T F C^T \lambda_*$, тому

$$\left(\hat{\theta} - \theta_*\right)^T F^T F\left(\hat{\theta} - \theta_*\right) = \lambda_*^T C F^T F C^T \lambda_* \qquad (3.1.4)$$

$$CF^T F\theta_* - T\theta_* + CT^T \lambda_* CF^T Y - \tau_0.$$

Остання рівність переписується таким чином:

$$CF^T F C^T \lambda_* = \hat{\tau} - \tau_0$$

і $\lambda_* = V^{-1}(\hat{\tau} - \tau_0)$. Підставивши в (3.1.4), отримаємо потрібне зображення. Лема доведена.

Із доведеної леми випливає, що $\mathcal{F} = \dfrac{R_1^2 - R_0^2}{k} \Big/ \dfrac{R_0^2}{N-r}$. Обчислення, які проводяться для знаходження статистики $\mathcal{F}$, утворюють так звану таблицю дисперсійного аналізу.

	Кількість степенів вільності	Сума квадратів	Середній квадрат
Залишкова сума	N-r	$R_0^2 = \min\limits_{\theta} (Y - F\theta)^T (Y - F\theta)$	$\dfrac{R_0^2}{N-r}$

Повна сума	N-r+k	$R_1^2 = \min\limits_{\theta: T\theta = r} (Y - F\theta)^T (Y - F\theta)$	
Відхилення від гіпотези	k	$R_1^2 - R_0^2$	$\dfrac{R_1^2 - R_0^2}{N - r}$

Задачі перевірки лінійних гіпотез H_0 вигляду (3.1.3) про параметри лінійної регресійної моделі називають задачами дисперсійного аналізу.

При цьому часто припускають, що змінні, від яких залежить функція регресії, є якісними, тобто приймають скінченне число значень, що відповідає якимось якостям. Такі змінні в задачах дисперсійного аналізу називають факторами. Значення, які може приймати той чи інший фактор, називають його рівнями. Множину допустимих рівнів кількісного фактора звичайно зображають у вигляді відрізка прямої, якісного – у вигляді множини чисел. Часто кількісний фактор приймає значення на двох рівнях – 0 і 1. Це може бути відсутність чи наявність якогось інгредієнта в суміші, участь або неучасть якоїсь речовини в реакції. В інших випадках кількість рівнів є більшою ніж два (наприклад, кількість різних сортів насіння в с/г експерименті, кількість різних варіантів доз ліків). Задачі планування експерименту в дисперсійному аналізі носять специфічний характер і скеровані в основному на зменшення кількості вимірів, які проводяться, і на спрощення процедури аналізу. Такі задачі ми розглянемо в розділі 2, а в цьому місці, як приклад розглянутої методики перевірки гіпотез, розглянемо задачу однофакторного аналізу, яка є найпростішою задачею подібного типу.

3.2.Однофакторний дисперсійний аналіз.

Припустимо, що задано m повторних вибірок $Y_1 = (y_{11},...,y_{1N_1})^T$,…, $Y_m = (y_{m1},...,y_{mN_m})^T$ об'ємів $N_1,...N_m$ із значень нормально розподілених випадкових величин з невідомими середніми $\theta_1,...,\theta_m$ і невідомою загальною дисперсією σ^2. Припускається, що виміри $y_{ij} = \theta_i + \varepsilon_{ij}$ *(i=1,…,m; j=1,…,*N_i*)* проводились при різних значеннях деякого фактору, вплив якого проявляється у зміні середнього значення θ_i. Гіпотеза

$$H_0 : \theta_1 = \theta_2 = ... = \theta_m \qquad (3.2.1)$$

означає, що згаданий фактор на результати вимірів не впливає. Задача перевірки гіпотези (3.2.1) за результатами вимірів може бути записана у вигляді задачі перевірки гіпотези про параметри регресійної моделі, якщо покласти :

$N = N_1 + ... + N_m$, $\theta = (\theta_1,...,\theta_m)^T$.

$Y = (y_{11},...,y_{1N_1},...,y_{m1},...,y_{mN_m})^T$.

$$F^T = \begin{bmatrix} 11\ldots1 & 00\ldots0 & \ldots & 00\ldots0 \\ 00\ldots0 & 11\ldots1 & \ldots & 00\ldots0 \\ \ldots & \ldots & \ldots & \ldots \\ \underbrace{00\ldots0}_{N_1} & \underbrace{00\ldots0}_{N_2} & \ldots & \underbrace{11\ldots1}_{N_m} \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & 0 & \dots & 0 & -1 \\ 0 & 1 & \dots & 0 & -1 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 & -1 \end{bmatrix}; \ \tau_0 = 0 \ ; \ k = m-1, \ r = m \ .$$

Якщо гіпотеза (3.2.1) є вірною, тобто всі θ_i *(i=1,...,m)* є рівними між собою, то мінімум суми квадратів відхилень рівний:

$$R_1^2 = \min_{\theta_1} \sum_{i,j=1}^{N} \left(y_{ij} - \theta_1\right)^2 = \sum_{i,j=1}^{N} y_{ij}{}^2 - \frac{1}{N}\left(\sum_{i,j=1}^{N} y_{ij}\right)^2 .$$

Залишкова сума квадратів

$$R_0^2 = \min_{\theta_1,\dots,\theta_m} \sum_{i,j} \left(y_{ij} - \theta_i\right)^2 = \sum_i \min_{\theta_i} \sum_j \left(y_{ij} - \theta_i\right)^2 = \sum_{i=1}^{m} \left(\sum_{,j=1}^{N_i} y_{ij}^2 - B_i^2 / N_i \right) \text{де}$$

$$B_i = \sum_{j=1}^{N_i} y_{ji} \ .$$

Отже, сума квадратів за рахунок відхилення від гіпотези має m-1 ступінь вільності і дорівнює $R_1^2 - R_0^2 = \frac{B_1^2}{N_1} + \dots + \frac{B_m^2}{N_m} - \frac{B^2}{N}$, де $B = B_1 + \dots + B_m = \sum y_{ij}$.

На практиці доцільніше спочатку обчислити R_1^2 і $R_1^2 - R_0^2$ за вказаними формулами, а потім обчислювати R_0^2; відповідна таблиця дисперсійного аналізу виглядає так:

	Кількість степенів вільності	Сума квадратів	Середній квадрат
Залишкова сума (Розбіжності в середині вибірок)	*N-m*	R_0^2 (отримується відніманням)	$\frac{R_0^2}{N-m}$
Повна сума	*N-1*	$R_1^2 = \sum_{i,j} y_{ij}^2 - \frac{B^2}{N}$	
Відхилення від гіпотези (Розходження між вибірками)	*m-1*	$R_1^2 - R_0^2 = \sum_{i=1}^{m} \frac{B_i^2}{N_i} - \frac{B^2}{N}$	$\frac{R_1^2 - R_0^2}{m-1}$